

**Classificação Automática de Gêneros Musicais a
partir das Letras**

Yuri Cordeiro de Almeida

Trabalho de Conclusão de Curso
MBA em Inteligência Artificial e Big Data

UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

**Classificação Automática de Gêneros Musicais a partir das
Letras**

*Estudo comparativo de modelos estatísticos e neurais de aprendizado de máquina
em Processamento de Linguagem Natural aplicado à música*

Yuri Cordeiro de Almeida

USP - São Carlos

2025

Yuri Cordeiro de Almeida

Classificação Automática de Gêneros Musicais a partir das Letras

Estudo comparativo de modelos estatísticos e neurais de aprendizado de máquina em Processamento de Linguagem Natural aplicado à música

Trabalho de conclusão de curso apresentado ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial.

Orientador: Prof. Dr. Ivandre Paraboni

USP - São Carlos

2025

Autorizo a reprodução e divulgação total ou parcial deste trabalho,
por qualquer meio convencional ou eletrônico para fins de estudo e
pesquisa, desde que citada a fonte.

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados inseridos pelo(a) autor(a)

d447c de Almeida, Yuri Cordeiro
Classificação Automática de Gêneros Musicais a
partir das Letras / Yuri Cordeiro de Almeida;
orientador Ivandre Paraboni. -- São Carlos, 2025.
51 p.

Trabalho de conclusão de curso (MBA em
Inteligência Artificial e Big Data) -- Instituto de
Ciências Matemáticas e de Computação, Universidade
de São Paulo, 2025.

1. CE610.4.1 – Aprendizado computacional. 2.
CE610.27.3 – Processamento de linguagem natural. 3.
CH741.19 – Música. I. Paraboni, Ivandre, orient. II.
Título.

Bibliotecários responsáveis pela estrutura de catalogação da publicação de acordo com a AACR2:
Gláucia Maria Saia Cristianini - CRB - 8/4938
Juliana de Souza Moraes - CRB - 8/6176

DEDICATÓRIA

Dedico esse trabalho à minha família: pais, avós e irmão(s), que me deram toda a base necessária para chegar até aqui. Graças aos seus cuidados pude tomar as melhores escolhas e trilhar um caminho frutífero e realizador, aprender de grandes mestres ao longo da vida, aos quais eu também dedico esse trabalho desde meu colégio Sion, a USP e agora nesse MBA.

Em especial, dedico à minha esposa Heloisa, minha parceira de vida e inspiração nesta etapa acadêmica. Com sua própria jornada, fez-me enxergar a oportunidade de evoluir e esteve presente em cada passo, oferecendo compreensão, paciência e incentivo nos momentos mais difíceis. Te amo.

Este trabalho também é de vocês.

AGRADECIMENTOS

Agradeço ao corpo docente do MBA e ao Instituto ICMC, sob a coordenação da professora Profa. Dra. Solange Rezende, que têm transformado a educação em Inteligência Artificial no Brasil, possibilitando o acesso a um conhecimento de excelência em um país que merece evoluir e assumir a liderança nessa área. Em especial, agradeço ao meu orientador, Prof. Dr. Ivandre Paraboni, que me instruiu de forma ímpar e esteve presente nos momentos cruciais, ajudando-me a avançar no caminho certo.

Registro também minha gratidão aos colegas da Turma 4 do MBA, que do início ao fim se apoiaram mutuamente, compartilhando aprendizados, dicas e soluções para os mais diversos desafios ao longo do curso. Tenho certeza de que são e serão profissionais de ponta no mercado, e torço pelo sucesso de todos.

Por fim, agradeço a Deus e a tudo que Ele me deu para chegar até aqui: a minha família que me acolheu; a esposa que me apresentou; e aos amigos que a vida trouxe e levou nos momentos certos, permitindo que eu trilhasse este percurso com saúde, força e sabedoria. Obrigado!

*“Ninguém ignora tudo. Ninguém sabe tudo. Todos nós sabemos alguma coisa.
Todos nós ignoramos alguma coisa. Por isso aprendemos sempre”.*

Paulo Freire
A importância do ato de ler. São Paulo: Cortez, 1989.

RESUMO

DE ALMEIDA, Y. C. **Classificação Automática de Gêneros Musicais a partir das Letras**. 2025. 52 f. Monografia (MBA em Inteligência Artificial e Big Data) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2025.

Prever o gênero das letras de música automaticamente é uma solução necessária a plataformas digitais e acervos onde metadados podem ser inconsistentes ou herdados diretamente do artista, o que compromete sistemas de recomendação e organização consistente. As letras, embora aparentemente menos ricas que o áudio, carregam traços semânticos e estilísticos que podem indicar estilos musicais, mesmo diante de variações como gírias, repetições e vocabulário informal.

Para estudar essa tarefa, foram encontradas boas fontes e processado um corpus balanceado de 2.400 músicas em oito gêneros principais (rock, pop, hip-hop, r-n-b, country, jazz, electronic e gospel), a partir das bases Kaggle, Spotify e Melon. Quatro abordagens principais foram comparadas: (i) baseline com TF-IDF combinado a classificadores lineares (Regressão Logística e SVM); (ii) modelo hierárquico HAN com *embeddings* pré-treinados; (iii) Transformers com *fine-tuning* (DistilBERT); e (iv) embeddings pré-treinados como MPNet combinados a classificadores leves.

Os resultados mostraram que o melhor desempenho geral foi obtido com MPNet + Regressão Logística (F1-macro = 0,50; acurácia = 0,51), seguido de perto pelo DistilBERT fine-tunado (F1-macro $\approx$ 0,49), embora a um custo computacional maior. O baseline TF-IDF + Regressão Logística manteve desempenho competitivo (F1-macro = 0,43), reforçando sua utilidade pela simplicidade e interpretabilidade. Já o HAN apresentou limitações em corpus reduzidos, apesar do potencial teórico de capturar hierarquias textuais.

A análise por gênero indicou que gospel e hip-hop foram mais facilmente identificáveis, enquanto pop, rock e r-n-b apresentaram maior sobreposição vocabular e temática. Conclui-se que é possível realizar classificação automática de gêneros musicais utilizando apenas letras, e que a escolha do modelo impacta não apenas a performance, mas também o custo interpretativo e computacional. A principal contribuição deste trabalho é oferecer uma comparação sistemática entre diferentes representações textuais e arquiteturas de classificação, discutindo suas limitações, potencialidades e aplicações na área de *Music Information Retrieval* (MIR).

Palavras-chave: Processamento de Linguagem Natural. Classificação de gêneros musicais. Letras de música. Aprendizado de máquina. Redes neurais. Inteligência Artificial.

ABSTRACT

DE ALMEIDA, Y. C. **Automatic Classification of Music Genres from Lyrics**. 2025. 52 f. Monograph (MBA in Artificial Intelligence and Big Data) – Institute of Mathematical and Computer Sciences, University of São Paulo, São Carlos, 2025.

Automatically predicting the genre of song lyrics is a necessary solution for digital platforms and collections where metadata may be inconsistent or inherited directly from the artist, which compromises recommendation systems and consistent organization. Lyrics, although seemingly less rich than audio, carry semantic and stylistic traits that can indicate musical styles, even in the face of variations such as slang, repetitions, and informal vocabulary.

To study this task, good sources were found and a balanced corpus of 2,400 songs in eight main genres (rock, pop, hip-hop, R&B, country, jazz, electronic, and gospel) was processed from the Kaggle, Spotify, and Melon1 databases. Four main approaches were compared: (i) baseline with TF-IDF combined with linear classifiers (Logistic Regression and SVM); (ii) hierarchical HAN model with pre-trained embeddings; (iii) Transformers with fine-tuning (DistilBERT); and (iv) pre-trained embeddings such as MPNet combined with lightweight classifiers.

The results showed that the best overall performance was obtained with MPNet + Logistic Regression (F1-macro = 0.50; accuracy = 0.51), closely followed by fine-tuned DistilBERT (F1-macro $\approx$ 0.49), albeit at a higher computational cost. The baseline TF-IDF + Logistic Regression maintained competitive performance (F1-macro = 0.43), reinforcing its usefulness due to its simplicity and interpretability. HAN, on the other hand, showed limitations in small corpora, despite its theoretical potential to capture textual hierarchies.

The analysis by genre indicated that gospel and hip-hop were more easily identifiable, while pop, rock, and R&B presented greater vocabulary and thematic overlap. We conclude that it is possible to perform automatic classification of music genres using only lyrics, and that the choice of model impacts not only performance but also interpretive and computational costs. The main contribution of this work is to offer a systematic comparison between different textual representations and classification architectures, discussing their limitations, potentialities, and applications in the area of Music Information Retrieval (MIR).

Keywords: Natural Language Processing. Music genre classification. Song lyrics. Machine learning. Neural networks. Artificial Intelligence.

LISTA DE ABREVIATURAS E SIGLAS

ABNT — Associação Brasileira de Normas Técnicas

AI / IA — *Artificial Intelligence* / Inteligência Artificial

ANN — *Artificial Neural Network* (Rede Neural Artificial)

BERT — *Bidirectional Encoder Representations from Transformers*

BoW — *Bag of Words*

DL — *Deep Learning*

F1-score — Medida de desempenho que combina precisão e revocação

GRU — *Gated Recurrent Unit*

HAN — *Hierarchical Attention Network*

LR — *Logistic Regression* (Regressão Logística)

ML — *Machine Learning* (Aprendizado de Máquina)

NLP / PLN — *Natural Language Processing* / Processamento de Linguagem Natural

PCA — *Principal Component Analysis* (Análise de Componentes Principais)

RF — *Random Forest*

SVM — *Support Vector Machine*

TF-IDF — *Term Frequency–Inverse Document Frequency*

XAI — *Explainable Artificial Intelligence*

SUMÁRIO

1 INTRODUÇÃO.....	31
2 OBJETIVO	33
3 FUNDAMENTAÇÃO TEÓRICA.....	33
4 METODOLOGIA	42
5 RESULTADOS E DISCUSSÃO	48
6 CONCLUSÕES.....	52
7 REFERÊNCIAS.....	54
GLOSSÁRIO.....	58

1 INTRODUÇÃO

A classificação de gêneros musicais é uma necessidade tanto da indústria fonográfica quanto em plataformas digitais. Historicamente, o gênero serviu como ferramenta de organização de acervos, curadoria editorial e segmentação de público. Com o avanço dos serviços de *streaming* e da tecnologia de produção musical, músicas são criadas e disponibilizadas a todo momento, muitas vezes com classificação herdada diretamente dos próprios artistas — o que pode ser eficaz em contextos de autoria, mas nem sempre se traduz em rótulos úteis para sistemas de recomendação automatizada. Em outros casos, a rotulação depende de usuários, o que adiciona ainda mais ruído e subjetividade ao processo, gerando desafios tanto conceituais quanto técnicos, pois não há consenso universal sobre o que define um gênero musical, nem consistência entre as taxonomias adotadas por diferentes plataformas. A área de *Music Information Retrieval* (MIR) investiga métodos computacionais para organizar, recuperar e analisar músicas, com destaque para a classificação de gênero. Abordagens tradicionais costumam empregar características acústicas — como timbre, ritmo e espectro sonoro — ou metadados oriundos de bases comerciais. No entanto, essas estratégias apresentam limitações importantes, como o elevado custo computacional e a complexidade em traduzir características acústicas em rótulos significativos (Downie, 2003; Schedl, Gómez & Urbano, 2014).

Letras de músicas carregam traços semânticos, temáticos e estilísticos que, embora menos estruturados que o áudio, podem refletir padrões associados a determinados gêneros. Foi apontado por Chomsky (1965) que a competência linguística humana envolve a capacidade de gerar frases inéditas a partir de regras gramaticais; nas letras, porém, essa regularidade é frequentemente subvertida por gírias, repetições e desvios criativos. Esses elementos, longe de serem ruído, tornam-se indicadores relevantes para modelos de classificação textual, como explorado por Ferreira et al. (2021) e Tsaptsinos (2017).

1.1 Problema e Justificativa

Conceitualmente, a identificação de gênero é mais frequentemente realizada a partir de características acústicas — como timbre, ritmo e espectro sonoro — ou de metadados oriundos de bases comerciais. No entanto, essas estratégias apresentam adversidades, seja pelo custo de processamento do áudio, pela disponibilidade

limitada de fontes ou pela baixa explicabilidade dos rótulos associados (Parmezan et al., 2020).

As letras de músicas, por sua vez, carregam traços semânticos, temáticos e estilísticos que, embora menos estruturados que o áudio, podem refletir padrões associados a determinados gêneros. Em estilos líricos mais descritivos, o uso de gírias ou construções poéticas pode servir como indicador relevante para modelos de classificação textual, como explorado por Ferreira et al. (2021) e Tsaptsinos (2017). Para essa tarefa, é necessário eleger uma representação textual adequada, transformando letras em vetores numéricos — etapa crítica para o desempenho dos modelos. Técnicas simples como *Bag of Words* e *TF-IDF* possuem capacidade limitada de capturar o contexto e as relações semânticas entre palavras (Caseli & Nunes, 2024), enquanto modelos baseados em *embeddings* ou atenção, como o BERT e suas variantes, exigem maior poder computacional e curadoria mais cuidadosa dos dados (Vaswani et al., 2017; Devlin et al., 2019). Além disso, as diferenças no uso da linguagem entre gêneros musicais podem impactar a capacidade de generalização dos modelos, exigindo estratégias robustas de classificação. Como a categorização de gêneros varia entre fontes como Spotify e YouTube, torna-se necessária uma padronização criteriosa para garantir coerência nos rótulos (Moreira & Tsunoda, 2021).

A proposta deste trabalho se justifica por três motivos principais: (i) letras são facilmente acessíveis e reutilizáveis, ao contrário do áudio bruto; (ii) modelos modernos de *Processamento de Linguagem Natural* (PLN) — área da inteligência artificial voltada à compreensão e geração automática de textos — são capazes de lidar com ambiguidade, polissemia e informalidade linguística, aspectos comuns nesse tipo de texto; e (iii) a rotulação de gênero envolve subjetividade e ruído, o que demanda modelos flexíveis e interpretáveis.

2. Objetivos

2.1 Objetivo geral:

Realizar uma análise comparativa entre diferentes abordagens de *aprendizado de máquina* — ramo da inteligência artificial que desenvolve métodos capazes de identificar padrões e tomar decisões a partir de dados — incluindo modelos estatísticos e redes neurais, aplicadas à classificação automática de gêneros musicais a partir das letras, buscando identificar qual dentre eles apresenta melhor desempenho em um mesmo corpus.

2.2 Objetivos específicos

- Avaliar modelos tradicionais como Bow/TF-IDF, destacando o classificador vencedor como baseline.
- Testar modelos neurais avançados baseados em Transformers.
- Avaliar um modelo hierárquico inspirado no HAN (*Hierarchical Attention Network*), verificando diferenças entre *embeddings* utilizados.
- Comparar o desempenho dos modelos segundo métricas quantitativas (F1-score e acurácia), considerando eficiência e capacidade computacional.
- Propor melhorias ou variações nos modelos testados, quando possível, para otimização do desempenho sobre o corpus estudado.

3. FUNDAMENTAÇÃO TEÓRICA

Nesta seção, apresentamos os principais conceitos que fundamentam este estudo, com foco nos aspectos diretamente relacionados à classificação de gêneros musicais por análise de letras.

3.1 Classificação de Gêneros Musicais e o Contexto do MIR

A tarefa de classificar gêneros musicais está inserida no campo de *Music Information Retrieval* (MIR) (Downie, 2003), área interdisciplinar que reúne técnicas para análise, categorização e recuperação de informações musicais. Ao longo do tempo, o escopo do MIR foi ampliado, incorporando não apenas o áudio, mas também letras, metadados e informações contextuais, o que reforça seu papel em sistemas modernos de recomendação e curadoria (Schedl, Gómez & Urbano, 2014).

Tradicionalmente, a classificação é feita com base em características acústicas, como os coeficientes cepstrais de frequência mel (*Mel-Frequency Cepstral Coefficients* — MFCCs), que resumem o espectro sonoro e são amplamente usados na extração de *features* de áudio (Bogdanov et al., 2019; Parmezan, Silva & Batista, 2020). Além dos MFCCs, utilizam-se espectrogramas e outros descritores de sinal. No entanto, essas abordagens exigem processamento especializado e não resolvem um problema fundamental: a definição de gênero musical é subjetiva, fluida e dependente de contexto (Parmezan, Silva & Batista, 2020). Essa subjetividade aparece nas taxonomias das plataformas digitais — o Spotify, por exemplo, reconhece mais de 1.500 gêneros musicais em sua base pública (Spotify for Developers, 2023), enquanto outras classificam a mesma faixa de modos distintos, como *indie rock* ou *rock alternativo*.

Essa falta de consenso reforça a importância de modelos com o uso de letras, que aproveitam dados acessíveis e podem capturar características textuais associados a gêneros. Neste trabalho, propõe-se a classificação, utilizando modelos de PLN e aprendizado de máquina. Para reduzir ruído de subgêneros, o escopo foi limitado a rótulos principais. Embora muitas músicas possam pertencer a múltiplos gêneros (classificação multilabel), optou-se por tratá-la como uma tarefa apenas multiclasse, onde cada instância é associada a um único gênero (Tsoumakas & Katakis, 2007). Essa decisão simplifica a análise e sustenta a padronização adotada na preparação da base.

3.2 Representações Textuais em PLN

O Processamento de Linguagem Natural (PLN) é uma subárea da Inteligência Artificial voltada a permitir que computadores compreendam e gerem linguagem humana (Caseli & Nunes, 2024). Abrange tarefas como análise sintática, extração de informação, tradução automática e modelagem semântica — esta última especialmente relevante neste estudo. Para que modelos de aprendizado de máquina lidem com linguagem natural, é necessário transformar palavras em representações numéricas que permitam o uso de técnicas estatísticas ou neurais. A linguística gerativa de Noam Chomsky (1957) inspirou os primeiros modelos formais de linguagem, baseados em regras matemáticas. Os *embeddings* modernos, por sua vez, adotam abordagem oposta: em vez de regras discretas, aprendem vetores densos a partir de grandes corpora, capazes de capturar relações semânticas emergentes (Mikolov et al., 2013; Pennington, Socher & Manning, 2014; Song et al., 2020). No contexto de letras musicais, essa etapa é especialmente relevante devido à variação estilística entre gêneros e ao uso de gírias e repetições. Nas seções a seguir, discutem-se três formas de representação textual: *Bag of Words*, *embeddings* estáticos e *embeddings* contextuais.

3.2.1 Bag-of-Words e TF-IDF

A técnica *Bag-of-Words* (BoW) representa cada documento por um vetor de frequências de ocorrência de palavras, ignorando a ordem e o contexto em que aparecem. Uma evolução do BoW é o *Term Frequency–Inverse Document Frequency* (TF-IDF), que pondera os termos não apenas pela frequência no documento, mas também pela raridade nos demais documentos do corpus (Caseli & Nunes, 2024; Raschka, 2015). Formalmente, o peso de um termo t em um documento d é dado por:

$$tfidf(t, d) = tf(t, d) \times \log\left(\frac{N}{df(t)}\right)$$

onde $tf(t, d)$ é a frequência de t em d , N é o número total de documentos e $df(t)$ é o número de documentos em que t ocorre.

Por exemplo, em um corpus com mil letras, se a palavra *love* aparece dez vezes em uma música e em apenas cinco documentos no total, seu peso TF-IDF será alto; já palavras comuns como *the* ou *and*, presentes em quase todas as letras, recebem peso próximo de zero.

3.2.2 Word Embeddings Estáticos

Com o avanço do PLN, surgiram estruturas para representar palavras em vetores densos e contínuos, conhecidos como *embeddings* estáticos. Técnicas como Word2Vec (Mikolov et al., 2013), GloVe (Pennington, Socher & Manning, 2014) e FastText (Bojanowski et al., 2017) aprendem representações semânticas com base no contexto local das palavras, de modo que termos com significados semelhantes tendem a ocupar regiões próximas no espaço vetorial, capturando relações como analogias, sinonímia e proximidade temática.

Embora mais eficazes que o TF-IDF na captura de semântica, esses modelos atribuem sempre o mesmo vetor a uma palavra, independentemente do seu uso no texto. Essa limitação é particularmente sensível no domínio musical, em que o contexto pode alterar significativamente o significado de expressões. Conforme apresentado por Caseli & Nunes (2024), essas restrições motivaram o desenvolvimento de representações mais avançadas, conhecidas como *embeddings* contextuais.

3.2.3 Embeddings Contextuais com Transformers

A principal revolução recente em PLN ocorreu com os modelos baseados em atenção, especialmente com o Transformer (Vaswani et al., 2017) e sua variante bidirecional BERT (Devlin et al., 2019). Diferentemente dos métodos anteriores, esses modelos geram *embeddings* distintos para uma mesma palavra, dependendo do seu contexto específico. Isso os torna mais aptos a lidar com polissemia e ambiguidade — características comuns em letras musicais e na língua natural de forma geral.

BERT é pré-treinado em grandes volumes de texto por meio de tarefas como o mascaramento de palavras e a previsão de próxima sentença, sendo posteriormente ajustado para tarefas específicas por meio de *fine-tuning*. Variações como RoBERTa e DistilBERT oferecem alternativas otimizadas para diferentes cenários de uso. No contexto brasileiro, destaca-se o BERTimbau, modelo pré-treinado em corpora da língua portuguesa (Souza et al., 2020). Para detalhes sobre seu uso em arquiteturas de classificação, remetemos à seção 3.3.2.

3.2.4 Sentence-BERT e MPNet

Modelos baseados em Transformer, como o BERT e o RoBERTa, apresentam bom desempenho na geração de *embeddings* para palavras e sentenças. No entanto, sua estrutura original não é ideal para tarefas que envolvem a comparação direta entre frases completas, como é o caso da classificação de documentos curtos — a exemplo das letras de músicas. Para suprir essa limitação, a arquitetura Sentence-BERT (Reimers & Gurevych, 2019) propõe uma adaptação dos Transformers para produzir vetores fixos que representam sentenças inteiras, otimizados para uso com classificadores lineares ou para tarefas de similaridade semântica.

Dentre os modelos da família Sentence-BERT, destaca-se o all-mpnet-base-v2, que utiliza o encoder MPNet (*Masked and Permuted Pretraining for Language Understanding*; Song et al., 2020). Esse modelo incorpora duas inovações importantes em relação ao BERT tradicional: (i) a combinação de estratégias de pré-treinamento com *masked language modeling* e *permutation language modeling*, o que melhora a captação de dependências de longo prazo; e (ii) o uso de uma arquitetura baseada em permutação, que permite prever múltiplos tokens em sequência e reforça o entendimento bidirecional do contexto.

3.3 Métodos de Classificação

O passo seguinte consiste em aplicar algoritmos de classificação capazes de identificar padrões, similaridades e incidências entre gêneros musicais. Em termos de *aprendizado de máquina*, esses algoritmos pertencem à categoria supervisionada, em que cada instância de treino é associada a um rótulo conhecido (Caseli & Nunes, 2024). O objetivo, portanto, é aprender uma função que estime o gênero mais provável de novas letras. Nesta seção, são apresentados três grupos de abordagens: métodos tradicionais, modelos hierárquicos e arquiteturas baseadas em *embeddings*.

3.3.1 Métodos de classificação tradicionais

Modelos lineares e estatísticos continuam sendo amplamente utilizados como baseline em tarefas de classificação de texto. Entre eles, destacam-se a Regressão Logística e o *Support Vector Machine* (SVM), que têm demonstrado desempenho competitivo quando aplicados sobre representações vetoriais esparsas, como *Bag-of-Words* com TF-IDF. As definições a seguir são baseadas em Caseli & Nunes (2024), referência recente em Processamento de Linguagem Natural, e complementadas pelo

conteúdo abordado nas disciplinas de Aprendizado de Máquina e Processamento de Linguagem Natural do MBA em Inteligência Artificial e Big Data da USP.

Regressão Logística é um modelo linear que estima a probabilidade de uma instância pertencer a uma classe específica, a partir de uma combinação linear das variáveis de entrada. Essa combinação é transformada pela função sigmoide, que mapeia os valores para o intervalo contínuo entre 0 e 1. Em problemas multiclasse, a Regressão Logística pode ser estendida por estratégias como *one-vs-rest*, em que são treinados K classificadores binários (um por classe) e a decisão final é feita pela maior probabilidade. No contexto de letras musicais representadas por TF-IDF, isso significa que cada palavra do vocabulário recebe um peso no vetor de coeficientes: termos como *love* podem aumentar a probabilidade de classificação como *pop*, enquanto *pray* ou *lord* reforçam a associação com *gospel*.

Support Vector Machines (SVM), por sua vez, buscam encontrar o hiperplano que melhor separa as classes no espaço de características, maximizando a margem entre exemplos próximos de classes distintas. Em representações textuais esparsas como BoW ou TF-IDF, cada dimensão corresponde a uma palavra, e o modelo aprende quais termos mais contribuem para distinguir os gêneros. Palavras como *baby* e *dance* podem posicionar instâncias em uma região associada ao *pop*, enquanto termos como *church* e *pray* aproximam documentos da região associada ao *gospel*. Essa capacidade de operar em alta dimensionalidade, aliada ao uso de funções de *kernel* para lidar com separações não lineares, explica por que o SVM é recorrente em classificações de texto com grande número de atributos.

3.3.2 Modelos Neurais Baseados em Transformers

A introdução dos Transformers (Vaswani et al., 2017) revolucionou o Processamento de Linguagem Natural ao propor um novo paradigma baseado em atenção auto-dirigida, capaz de modelar relações contextuais entre todas as palavras da sequência simultaneamente. Diferentemente de modelos sequenciais como RNNs (Redes Neurais Recorrentes) ou LSTMs, os Transformers dispensam o processamento sequencial, ganhando paralelismo e escala.

Modelos como BERT (Devlin et al., 2019) e RoBERTa (Liu et al., 2019) elevaram esse paradigma ao incorporar pré-treinamento massivo com tarefas como *Masked Language Modeling* (MLM), permitindo que a rede aprenda padrões sintáticos e semânticos ricos a partir de grandes volumes de texto. Isso é especialmente relevante

para letras de música, cuja estrutura pode conter polissemia, ironia ou ambiguidade — situações em que a palavra só adquire sentido à luz do restante do texto.

Por exemplo, o termo “moral” pode ser associado a um discurso religioso (*gospel*), a uma crítica social (*rap*), ou ao auto engrandecimento (*funk*), dependendo do contexto. Modelos como o BERT geram *embeddings* distintos para cada ocorrência desse termo, ajustados ao contexto, o que os torna extremamente eficazes nesse domínio. No contexto do português, destaca-se o BERTimbau (Souza et al., 2020), pré-treinado especificamente em corpora lusófonos, o que garante melhor aderência morfosintática às estruturas do português brasileiro. Entretanto, a sofisticação técnica desses modelos traz também custos computacionais elevados e menor transparência interpretativa. Em muitas aplicações, não é trivial identificar quais partes do texto foram decisivas para a predição, o que limita sua adoção em cenários em que a explicabilidade é desejada. Ainda assim, sua precisão em tarefas de classificação justifica seu uso como modelo principal neste estudo.

3.3.3 Modelos Hierárquicos

As letras de música seguem uma composição estruturada em partes como introdução, estrofes, refrões e pontes, cuja disposição e recorrência variam entre gêneros. O *Hierarchical Attention Network* (HAN), proposto por Yang et al. (2016), modela explicitamente essa organização hierárquica textual, utilizando mecanismos de atenção em dois níveis: palavras e sentenças.

Adaptado por Tsaptsinos (2017) para o domínio musical, o HAN demonstrou eficácia em classificar gêneros ao considerar que diferentes trechos da música possuem peso semântico desigual. Por exemplo, uma única linha de um refrão repetitivo pode ser mais discriminativa do que longas estrofes genéricas. Na formulação original, os pesos atencionais em cada nível permitem aprender não apenas a representação, mas também quais partes do texto importam mais para cada classe.

Essa característica confere ao HAN um grau de interpretabilidade, já que os pesos de atenção podem ser visualizados para indicar palavras ou sentenças mais relevantes. No entanto, no presente trabalho foi utilizada uma versão simplificada, inspirada no HAN, que preserva a estrutura hierárquica palavra–sentença–documento, mas substitui a atenção por *pooling*. Essa adaptação priorizou viabilidade experimental e reduziu custo computacional, embora tenha eliminado a interpretabilidade direta do

modelo original. Ainda assim, a abordagem hierárquica se mostra relevante para análise de letras, permitindo analisar fatores em diferentes níveis do texto.

3.4 Trabalhos Relacionados

Alguns estudos prévios fundamentam as decisões metodológicas deste trabalho. Um bem relevantes é o de Tsaptsinos (2017), que aplicou o *Hierarchical Attention Network* (HAN) para classificação de gêneros musicais a partir das letras. O autor utilizou um corpus de 495.188 canções, avaliando tanto 117 gêneros quanto um recorte agregado de 20. O HAN alcançou 46,4% de acurácia em 117 gêneros e 49,5% em 20, superando LSTMs tradicionais em cenários complexos e evidenciando o potencial de arquiteturas hierárquicas no domínio lírico.

Em uma linha mais tradicional, Ferreira et al. (2021) aplicaram modelos supervisionados clássicos — como Support Vector Machine (SVM), Random Forest e Naïve Bayes — em letras de músicas vetorizadas com TF-IDF, alcançando Macro-F1 em torno de 0,35–0,40. Esses resultados confirmam o valor do TF-IDF como baseline, em linha com Caseli & Nunes (2024), que ressaltam tanto sua utilidade em cenários controlados quanto suas limitações frente a representações mais densas.

Migrando para embeddings densos, Kumar et al. (2018) testaram Word2Vec simples e uma versão híbrida Word2Vec+TF-IDF em um corpus de 19 mil canções de quatro gêneros (Christian, Metal, Country e Rap). Comparando classificadores clássicos e uma rede neural profunda, observaram ganhos relevantes: o Word2Vec atingiu até 65% de acurácia, enquanto a versão híbrida chegou a 74% com DNN. Esse estudo marca a passagem das representações esparsas para densas e abriu espaço para técnicas mais ricas, como FastText e MPNet, exploradas neste trabalho.

Com a chegada dos Transformers, o desempenho avançou significativamente. Akalp (2021) comparou BERT, DistilBERT e BiLSTM, mostrando que o BERT atingiu 77,6% em classificação monorrótulo e 71,3% em multilabel. Já Pizarro (2024) aplicou DistilBERT em tarefas de gênero, popularidade e ano de lançamento, utilizando o dataset da Genius. Apesar de 65% de acurácia em gênero, obteve 79% em popularidade e destacou a dificuldade em distinguir gêneros semanticamente próximos, como pop e rock — reforçando tanto o poder quanto os limites dos embeddings contextuais.

Outra vertente é a classificação multilabel e multilíngue. Fernandes Tavares (2025) utilizou Sentence-BERT em um cenário cross-lingual, demonstrando que é possível

treinar modelos em uma língua e aplicá-los em outra. O estudo mostrou ganhos expressivos sobre o baseline de tradução + BoW, elevando o F1 médio de 0,35 para 0,69, além de permitir múltiplos gêneros por faixa. Esse resultado contrasta com a opção adotada neste trabalho — o foco exclusivo no inglês e no formato apenas multiclasse — e aponta perspectivas futuras.

Também merece destaque a questão da explicabilidade. Embora focado em áudio, Desta et al. (2025) trataram da classificação de gêneros musicais a partir de features acústicas (como MFCCs e espectro) combinadas a um classificador Random Forest. O diferencial do estudo foi a aplicação de técnicas de XAI (*Explainable AI*) — em particular, SHAP e LIME — sobre o modelo treinado, permitindo identificar quais atributos acústicos tiveram maior peso em cada decisão. Embora restrito a algoritmos clássicos, o trabalho mostrou que é possível alcançar cerca de 90% de acurácia em seu corpus e, sobretudo, explicar as predições.

Para finalizar, outro ponto de atenção destacado na literatura é a padronização dos rótulos de gênero. Moreira e Tsunoda (2021) destacam a inconsistência entre diferentes fontes ao propor uma base de músicas brasileiras, reforçando a necessidade de consolidação. Além disso, estudos como o de Parmezan et al. (2020) mostraram que a organização hierárquica de gêneros em áudio melhora a acurácia, o que indica que estratégias de hierarquização também podem ser exploradas em trabalhos futuros no contexto de letras.

Em conjunto, esses trabalhos mostram uma vasta gama de possibilidades a serem exploradas em classificação de letras: dos modelos esparsos baseados em TF-IDF (Ferreira), passando por *embeddings* densos (Kumar), abordagens hierárquicas (Tsaptsinos), até os Transformers (Akalp, Pizarro). Complementam-se ainda contribuições em multilabel e multilíngue (Tavares) e interpretabilidade (Desta). Apesar dos avanços, permanece uma lacuna em estudos que comparem os melhores resultados entre eles sobre um mesmo corpus, onde se encontra a principal contribuição deste trabalho. Vale destacar que poucos trabalhos lidam com mais de oito classes simultaneamente, sendo esse um diferencial do presente estudo, que adota oito gêneros principais em formato multiclasse balanceado

4. Metodologia

Com o objetivo de investigar o desempenho de abordagens de *Machine Learning* em classificação automatizadas de gêneros musicais a partir de letras, foi conduzida uma série de experimentos comparativos com diferentes estratégias de representação textual e arquiteturas de classificação. A escolha dos modelos foi motivada tanto por estudos relacionados na literatura quanto pelas características observadas na análise exploratória do corpus. As abordagens testadas vão desde representações tradicionais baseadas em frequência até redes neurais hierárquicas e *transformers* com *embeddings* contextuais, com e sem *fine-tuning* supervisionado.

4.1 Estratégias de Modelagem

Foram implementadas quatro modelos de classificação supervisionada principais: (i) BoW com **TF-IDF**, adotado como baseline clássico; (ii) **MPNet**, explorando *embeddings* pré-treinados como representações fixas; (iii) **DistilBERT**, representando a aplicação direta de Transformers no corpus; e um (iv) modelo **Hierárquico** inspirado no HAN, uma rede neural em níveis de palavras e sentenças por meio de GRUs bidirecionais e *pooling*. Assim como algumas variações em cada grupo, seja de parâmetros, classificadores ou opções de *embeddings* conforme descritos a seguir.

4.1.1 BoW com TF-IDF e classificadores lineares

Nesta estratégia inicial, empregou-se o `TfidfVectorizer` com `max_features=5000` e `ngram_range=(1,2)`. Esse número de *features* foi definido após testes preliminares, representando um ponto de equilíbrio entre representatividade e custo computacional, evitando explosão de dimensionalidade. A inclusão de bigramas permitiu capturar ocorrências relevantes, conforme já indicado na literatura de classificação de textos curtos (Raschka, 2015). Foram avaliados dois classificadores lineares:

- Regressão Logística Multinomial (`solver='lbfgs'`, `multi_class='multinomial'`, `max_iter=1000`), indicada para problemas multiclasse por convergir rapidamente e lidar bem com penalizações L2 (Raschka, 2015).
- SVM Linear (`LinearSVC`, `C=1.0`, `penalty='l2'`, `loss='squared_hinge'`, `max_iter=1000`), amplamente utilizada em classificação de texto por sua

robustez em espaços de alta dimensionalidade e margens máximas, sendo uma referência em benchmarks de PLN (Joachims, 1998).

4.1.2 MPNet e outros *embeddings* via HuggingFace

O modelo all-mpnet-base-v2 foi utilizado no modo *feature extraction* (sem *fine-tuning*), gerando *embeddings* de 768 dimensões para cada letra e aproveitando o conhecimento adquirido em grandes corpora para produzir representações semânticas. Além disso, a implementação foi feita de forma adaptável com a biblioteca HuggingFace, permitindo o teste de outros modelos de *embeddings*. Sendo assim, além do experimento MpNet principal, foram exploradas algumas variações:

- Uma versão MpNet com redução de dimensionalidade via PCA para 256 dimensões, visando diminuir o tempo de treino e reduzir risco de overfitting. Nessa configuração, foi avaliado também o uso do classificador Random Forest, como alternativa não linear à Regressão Logística.
- Outra com concatenação de atributos estruturais (ex.: número de palavras, densidade lexical) aos *embeddings*, com impacto negativo pequeno, mas medido nos testes – classificador Regressão Logística.
- Outros *embeddings* foram testados aproveitando a adaptabilidade da biblioteca HuggingFace, mantendo a Regressão Logística como classificador.

4.1.3 DistilBERT *fine-tuned*

O DistilBERT é uma versão compacta do BERT, com cerca de 40% menos parâmetros, mantendo aproximadamente 97% do desempenho do modelo original (Sanh et al., 2019). Foi empregado no modo *fine-tuning* supervisionado, adicionando uma camada densa de classificação e ajustando todos os pesos do modelo com *backpropagation* sobre o corpus balanceado.

O comprimento máximo de sequência (`max_length=512`) foi adotado para evitar truncamento excessivo das letras, cobrindo a maioria dos casos sem ultrapassar limites de GPU. O número de épocas foi definido após testes para evitar sobreajuste, e o *batch_size* foi ajustado aos limites de memória do Colab, mantendo estabilidade no treinamento. Foram testadas algumas iterações até se atingir o melhor resultado com 3 Épocas, *Batchsize* 16 e *Learning Rate* 3e-5.

4.1.4 Rede Neural Hierárquica

Inspirado no *Hierarchical Attention Network* (HAN), foi implementado um modelo hierárquico com GRUs bidirecionais em ambos os níveis, escolhidas por oferecer menor custo computacional que LSTMs e ainda capturar dependências de longo prazo. Diferentemente do HAN original, que utiliza mecanismos de atenção, esta versão empregou pooling para resumir as representações. Foram testados dois conjuntos de embeddings pré-treinados:

- GloVe 100d — dimensionalidade compacta, boa cobertura para inglês e menor custo de memória.
- FastText 300d — maior dimensionalidade e capacidade de lidar com palavras fora do vocabulário (OOV), ampliando a cobertura lexical.

O limite de entrada foi definido em 15 sentenças por documento e 20 palavras por sentença, resultando em aproximadamente 300 *tokens* processados por exemplo — valor suficiente para cobrir a maioria das letras sem inviabilizar o processamento. A etapa final de classificação foi realizada pela própria rede, com uma camada densa intermediária (ReLU) e uma camada softmax responsável pela previsão do gênero musical.

4.2 Base de Dados

O dataset utilizado neste trabalho foi construído a partir da fusão de três fontes complementares: um corpus de letras do Kaggle, atributos musicais do Spotify e classificações auxiliares do serviço Melon. As letras foram extraídas da base “Scrapped Lyrics from 79 Musical Genres” (Kaggle), que contém centenas de milhares de músicas com informações sobre idioma, artista e letra completa. Entretanto, os gêneros originais desse corpus apresentavam forte viés por serem herdados do artista (em vez da faixa) e frequentemente configuravam um problema de classificação multilabel. Para mitigar esses problemas, realizou-se uma integração com fontes mais confiáveis e padronizadas, conforme descrito na próxima seção.

O dataset final — contendo versões completa — foi disponibilizado publicamente para reprodutibilidade e uso acadêmico. Os arquivos e scripts correspondentes podem ser acessados no repositório GitHub do projeto (<https://github.com/yuricordeiro/tcc-mba-ia-usp>) e/ou na página do dataset no Kaggle

(<https://www.kaggle.com/datasets/yuricordeiro/tcc-mba-ia-usp>).

4.2.1 Coleta e Preparação dos Dados

O corpus textual foi enriquecido com atributos do “Spotify Tracks Dataset” (Kaggle), que fornece rótulos curados e single-label para o gênero musical, além de métricas como popularidade e características acústicas. O Melon Playlist Dataset, disponibilizado pelo Music Technology Group da Universitat Pompeu Fabra (Bogdanov, 2019), foi utilizado apenas para complementação de gêneros onde não houve equivalência, após sua tradução e padronização para o formato de gêneros do Spotify, contribuindo para ampliar a diversidade do conjunto e fortalecer a consistência taxonômica. Apesar disso, os gêneros fornecidos pelo Spotify foram adotados como padrão principal de rotulagem.

Durante o processo de preparação, todas as letras foram filtradas para manter apenas aquelas escritas em inglês. A escolha pela língua inglesa foi motivada pela baixa quantidade de exemplos em português com rótulos confiáveis após a normalização dos dados. O dataset final foi balanceado, contendo exatamente 300 músicas para cada um dos oito gêneros com maior representatividade: rock, pop, hip-hop, r-n-b, country, jazz, electronic e gospel — totalizando 2.400 amostras conforme a Tabela 1.

Tabela 1 — Distribuição do corpus por gênero.


Gênero	Total original	Selecionado
Rock	9.669	300
Pop	6.323	300
Hip-hop	2.802	300
R-n-b	2.705	300
Country	1.462	300
Jazz	722	300
Electronic	701	300
Gospel	335	300

4.2.2 Análise Exploratória

Com o objetivo de compreender melhor a estrutura textual das letras antes da modelagem, foi realizada uma análise exploratória quantitativa por gênero. Para cada música foram extraídas estatísticas como o número total de palavras, versos, estrofes e palavras únicas. Em seguida, foram agregadas médias, desvios padrão e extremos (mínimo e máximo) por gênero, revelando padrões interessantes. O gênero hip-hop, por exemplo, se destacou por conter, em média, o dobro de palavras e versos em comparação aos demais estilos, enquanto gêneros como jazz e gospel apresentaram estruturas mais enxutas e regulares.

A Figura-1 resume o perfil textual médio por gênero, considerando comprimento das letras, número de versos e vocabulário único normalizados de forma a observarmos as distâncias e diferenças estruturais centralizadas.

Figura 1 — Perfil textual médio por gênero.




A Tabela 2 a seguir detalha esses valores numericamente sem normalização. Vale destacar uma observação em relação a definição de estrofe que pode ser qualquer composição de versos, incluso únicas frases com dupla quebra de linha.

Tabela 2 — Estatísticas textuais médias por gênero.

Gênero	Palavras médias	Versos médios	Estrofes médias	Palavras únicas médias
Hip-hop	536.4	75.0	8.3	223.2
R-n-b	320.4	51.1	8.9	111.0
Pop	285.9	47.2	9.2	95.5
Electronic	238.0	40.1	7.7	82.8
Country	231.2	34.8	6.6	97.5
Rock	222.0	37.4	7.7	91.0
Gospel	207.4	35.8	7.2	82.5
Jazz	149.0	24.8	5.4	72.0

Além disso, na Figura 2 foi conduzida uma análise léxica com remoção de *stopwords* que são termos pouco informativos como conjunções preposições e artigos. As palavras mais frequentes por gênero demonstraram tanto padrões universais quanto vocabulário distintivo. Por exemplo, a palavra "love" apareceu com alta frequência em quase todos os estilos, especialmente em r-n-b e gospel.

Figura 2 — Palavras mais frequentes por gênero.



Por outro lado, termos como “*god*” e “*baby*” mostraram-se mais específicos de gospel e r-n-b, respectivamente — características que ajudam a explicar o bom desempenho desses gêneros nas métricas de classificação, sobretudo quando se utiliza vetorização por TF-IDF ou *embeddings* contextuais, que se beneficiam da presença de *tokens* discriminativos.

5. Resultados e Discussão

5.1 Procedimento Experimental

Todos os modelos foram treinados com divisão estratificada (80/20) do corpus balanceado. Para garantir reprodutibilidade, todos os experimentos foram executados com semente fixa (*random_state* = 42). A métrica principal foi o F1-score macro, escolhida por considerar o desempenho médio entre classes e ser menos influenciada por possíveis desbalanceamentos. Os modelos baseados em *transformers* foram treinados com otimizações específicas: redução de *batch size*, *learning rates* menores e *early stopping*. Modelos clássicos utilizaram regularização padrão, e em alguns casos ajustes manuais de hiperparâmetros foram realizados por experimentação incremental. O código dos experimentos foi mantido modular e reprodutível.

5.2 Resultados

A Tabela 3 apresenta os resultados globais de F1-score macro e acurácia. Para essa exibição foram mantidos apenas os melhores representantes de cada grupo de modelos: TF-IDF + Regressão Logística no bloco clássico (superando SVM), MPNet + Regressão Logística entre os *embeddings* estáticos, DistilBERT com *fine-tuning* nos Transformers, e a rede hierárquica inspirada no HAN.


Tabela 3 — Desempenho dos modelos com melhor resultado de cada grupo.

Modelo	Tipo de Representação	Classificador	F1-score	Acurácia
MPNet + LogReg	Embedding pré-treinado	Regressão Logística	0,50	0,51
DistilBERT (refinado)	Transformer com fine-tuning	Camada linear + softmax	0,48	0,49
TF-IDF + LogReg	Vetores TF-IDF (5k, uni+bi)	Regressão Logística	0,43	0,44
Hierárquico + FastText	Estrutura palavra-sentença (GRU + pool)	Rede neural com camada densa + softmax	0,33	0,33

Conforme a Tabela 3, o modelo MPNet (*embedding* pré-treinado) e Regressão Logística apresentou o melhor desempenho geral, com F1-score de 0,50 e acurácia de 0,51, superando os demais grupos. Embora o DistilBERT com *fine-tuning* também tenha alcançado resultados competitivos (F1 = 0,48), exigiu maior custo computacional e tempo de processamento, sem superar a eficiência do MPNet..

Para complementar, a Figura 3 traz os 10 experimentos mais relevantes para compreender variações dentro dos grupos, incluindo testes com bom resultado de outros *embeddings* estáticos (como MiniLM-L6 e E5-base), para confirmar a superioridade do MPNet nesse cenário, além de combinações com redução de dimensionalidade (PCA) e adicionando características estruturais. Testes preliminares de menor desempenho — como versões do HAN sem *embeddings* pré-treinados ou DistilBERT com menos épocas — foram descartados.

Figura 3 — Desempenho dos 10 modelos mais relevantes.



5.3 Discussão

Os resultados globais confirmam a superioridade das representações baseadas em *embeddings* pré-treinados. O modelo MPNet combinado à Regressão Logística atingiu o melhor desempenho, com F1-score macro de 0,50 e acurácia de 0,51. Esse resultado mostra que *embeddings* fixos de sentença, mesmo sem *fine-tuning*, são capazes de oferecer representações semânticas mais expressivas do que vetores esparsos como o TF-IDF. Essa constatação está em linha com trabalhos como o de Kumar et al. (2018), cujo melhor modelo híbrido Word2Vec+TF-IDF chegou a 0,74 de acurácia em apenas quatro gêneros, mas obteve F1 inferior a 0,50 em cenários mais

amplos, reforçando que classificadores lineares simples continuam competitivos quando associados a representações robustas.

O DistilBERT com *fine-tuning* obteve desempenho semelhante (F1 de 0,49), confirmando a tendência observada por Akalp (2021) e Pizarro (2024), de que *Transformers* são atualmente o estado da arte em classificação de letras. A proximidade de seus resultados em relação ao MPNet indica que, em cenários de corpus reduzido, embeddings estáticos aliados a classificadores lineares podem alcançar desempenho comparável a *Transformers* ajustados, com menor custo computacional.

Como esperado, o TF-IDF combinado à Regressão Logística apresentou desempenho inferior (F1 de 0,43), mas ainda competitivo como baseline. Esses resultados reproduzem a tendência já reportada por Ferreira et al. (2021), que mostraram F1 entre 0,35 e 0,40 em letras de músicas, e confirmam que representações esparsas, apesar de suas limitações semânticas, seguem relevantes pela interpretabilidade e pelo baixo custo. Essa constatação justifica a escolha de manter o TF-IDF neste estudo como base de comparação.


Em contrapartida, o HAN com *embeddings FastText* alcançou desempenho bem abaixo do esperado (F1 de 0,33), não superando sequer os baselines lineares. Esse resultado diverge do obtido por Tsaptsinos (2017), que relatou até 0,49 de acurácia em cenários com 20 gêneros. A discrepância evidencia a dependência da arquitetura a grandes volumes de dados e possível *tuning* refinado, e sugere que, nas condições deste estudo, o modelo não conseguiu explorar todo o seu potencial. Ainda assim, sua inclusão é metodologicamente importante, pois ilustra os desafios de treinar arquiteturas hierárquicas em cenários de dados restritos e reforça a necessidade de investigações futuras com corpora mais amplos.

Em síntese, os resultados mostram que *embeddings* modernos combinados a classificadores leves podem alcançar desempenho comparável a *Transformers* fine-tunados, enquanto representações tradicionais permanecem úteis como baseline. Ao mesmo tempo, o desempenho limitado do HAN contrasta com a literatura e reforça que arquiteturas hierárquicas exigem condições específicas para superar abordagens mais simples. Esses achados constituem a principal contribuição deste trabalho: oferecer uma comparação em um mesmo corpus lírico, destacando o equilíbrio entre desempenho, interpretabilidade e custo computacional.

5.4 Análise detalhada por Gênero


A Figura 4 apresenta um *heatmap* dos F1-scores por gênero e modelo. Ele fornece uma visão geral de como cada arquitetura se comporta em diferentes estilos musicais, destacando contrastes entre gêneros de fácil e difícil classificação.

Figura 4 — Heatmap de F1-score por gênero e modelo.



A Figura 5 mostra a distribuição dos resultados por gênero em formato de boxplot. Esse recurso complementa o *heatmap* ao evidenciar variação e consistência entre os classificadores no mesmo gênero.

Figura 5 — Distribuição de F1-score por gênero (boxplot).



A análise do desempenho por gênero, apresentada na Figura 4 evidencia diferenças importantes entre as classes. O gospel e o hip-hop apresentaram os maiores valores de F1 ($\approx 0,80$), independentemente do modelo, beneficiados por termos fortemente discriminativos e maior clareza de contexto nas letras. Em contrapartida, gêneros como *country* e *electronic* mostraram desempenho intermediário ($\approx 0,35$ – $0,47$), com vocabulário mais repetitivo, mas menos exclusivo.

A Figura 5 complementa essa visão ao destacar a variabilidade entre modelos. Nota-se que gêneros como rock, gospel, e até *country* e eletrônico apresentam maiores ganhos pontuais, isto é, há modelos que conseguem empurrar estes desempenhos para patamares superiores em comparação ao restante. Já em gêneros como pop e r-n-b, a dispersão é baixa e os resultados permanecem consistentemente fracos, sinalizando que mesmo os melhores modelos não conseguem extrair padrões claros nessas classes.

Em conjunto, os achados confirmam que a capacidade de classificação depende não apenas da técnica de representação, mas também do grau de distinção lexical e temática entre os gêneros.

6. Conclusão

Este trabalho apresentou uma série de experimentos para classificação automática de gêneros musicais a partir de letras, explorando desde representações tradicionais até arquiteturas modernas de PLN. Os resultados confirmaram que *MPNet* e *DistilBERT* superaram de forma consistente representações tradicionais como o TF-IDF, mesmo quando combinados a classificadores simples. O TF-IDF manteve relevância como baseline interpretável, enquanto o HAN reforçou sua dependência de bases maiores para alcançar bons resultados. A análise por gênero evidenciou diferenças de separabilidade entre classes, reforçando que a intersecção de vocabulário e temáticas permanece como principal desafio.

Apesar de ficar clara a superioridade dos modelos mais modernos, os resultados indicam que, para melhorar o desempenho em gêneros com maior variabilidade de temas e vocabulário, pode ser necessário adotar abordagens híbridas, explorando o melhor de cada técnica, como no trabalho de Kumar et al. (2018). Esse tipo de combinação pode equilibrar a robustez de *embeddings* pré-treinados com a interpretabilidade de métodos lineares, ou ainda unir classificadores leves com arquiteturas profundas, abrindo espaço para resultados mais consistentes em diferentes estilos musicais. Além disso, arquiteturas com Hierarquia palavra-sentença, que neste trabalho tiveram desempenho limitado, ainda representam alternativas promissoras, desde que aplicadas em corpora mais extensos e com *tuning* refinado para explorar plenamente seu potencial.

Em síntese, a principal contribuição deste trabalho foi oferecer uma comparação entre diferentes representações textuais e modelos de classificação aplicados a um mesmo corpus balanceado de letras musicais, evidenciando vantagens, limitações e condições de uso de cada abordagem. Ao reunir baselines clássicos, *embeddings* modernos e arquiteturas hierárquicas, o estudo preenche a lacuna identificada na literatura e fornece subsídios metodológicos para pesquisas futuras. Se, para Chomsky (1965), a beleza da linguagem residia no poder de regras finitas gerarem infinitas expressões, ao longo deste trabalho entendemos que os vetores densos e modelos atuais revelam outro infinito — o das relações emergentes em espaços contínuos de alta dimensão.

6.1 Trabalhos Futuros

Como extensão futura, propõe-se a integração do modelo de classificação textual de gênero a pipelines mais amplos de metadados musicais. Tal pipeline poderia combinar a inferência textual com o histórico de gêneros do artista e dados de curadoria social (como *playlists* ou classificações de usuários), permitindo a construção de classificadores compostos mais robustos e escaláveis para aplicações em plataformas de streaming, sites de letras e ferramentas de organização musical.

Outra direção promissora é o uso de modelos híbridos, combinando embeddings semânticos com atributos estruturais, ou arquiteturas profundas com classificadores lineares, que já mostraram sinais positivos em nossos experimentos. Além disso, ampliar o corpus, realizar treinamentos mais longos e explorar arquiteturas hierárquicas como o HAN e Transformers com fine-tuning completo podem permitir ganhos adicionais, aproveitando plenamente o potencial desses modelos em cenários de dados mais ricos.

Também se destacam os cenários de classificação multilabel e multilíngue, mais próximos da realidade, em que músicas podem receber múltiplos rótulos e circulam em diferentes idiomas. Finalmente, explorar LLMs contemporâneos representa um próximo passo natural — seja para classificação direta, enriquecendo as aplicações em recomendação e organização musical, ou até para geração de letras ou trechos em estilos específicos.

7. REFERÊNCIAS

- AKALP, H. Language Representation Models for Music Genre Classification Using Lyrics. *International Journal of Advanced Computer Science and Applications (IJACSA)*, v. 12, n. 5, p. 379–386, 2021. Disponível em: <https://doi.org/10.14569/IJACSA.2021.0120547>.
- CASELI, H. M.; NUNES, M. G. V. (org.). *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*. 3. ed. [S.I.]: BPLN, 2024. Disponível em: <https://brasileiraspln.com/livro-pln/3a-edicao>
- CHOMSKY, N. *Syntactic Structures*. The Hague: Mouton, 1957.
- CHOMSKY, N. *Aspects of the Theory of Syntax*. Cambridge, MA: MIT Press, 1965.
- DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: *Proceedings of NAACL-HLT*. [S.I.]: ACL, 2019. p. 4171–4186.
- DESTA, M. A.; MULU, C.; MOHAMMED, A. Y. Understanding the Decision-Making Process of Music Genre Classification with Explainable Algorithms. *Multimedia Research*, v. 8, n. 1, p. 1–10, jan. 2025. Disponível em: <https://doi.org/10.46253/j.mr.v8i1.a1>.
- FERREIRA, B. P. J. M. et al. Classificação de gêneros musicais utilizando SVM, Random Forest e Naïve Bayes. *Revista Brasileira de Computação Musical*, v. 10, n. 2, p. 45–62, 2021.
- JOACHIMS, T. Text categorization with Support Vector Machines: Learning with many relevant features. In: *European Conference on Machine Learning (ECML-98)*. Berlin: Springer, 1998. p. 137–142. Disponível em: <https://doi.org/10.1007/BFb0026683>.
- KUMAR, A. Feature Representations for Music Genre Classification. In: *International Conference on Computing, Analytics and Security Trends (CAST)*. [S.I.]: IEEE, 2018. p. 177–182. Disponível em: <https://doi.org/10.1109/CAST.2018.8644504>.
- LIU, Y. et al. RoBERTa: A Robustly Optimized BERT Pretraining Approach. *arXiv preprint*, arXiv:1907.11692, 2019.

MIKOLOV, T.; CHEN, K.; CORRADO, G.; DEAN, J. Efficient Estimation of Word Representations in Vector Space. *arXiv preprint*, arXiv:1301.3781, 2013.

MOREIRA, P. S.; TSUNODA, D. F. Proposta de base de dados para classificação automática de gêneros musicais brasileiros. *Revista Brasileira de Educação em Ciência da Informação*, v. 8, n. 1, p. 1–13, 2021.

PARMEZAN, A. R. S.; SILVA, D. F.; BATISTA, G. E. A. P. A. A Combination of Local Approaches for Hierarchical Music Genre Classification. In: *Proceedings of the 21st ISMIR Conference*. Montréal, Canadá: ISMIR, 2020.

PENNINGTON, J.; SOCHER, R.; MANNING, C. D. GloVe: Global Vectors for Word Representation. In: *Proceedings of EMNLP*. [S.l.]: ACL, 2014. p. 1532–1543.

PIZARRO MARTINEZ, S. Exploring Genre and Success Classification through Song Lyrics using DistilBERT. In: *Proceedings of the International Conference on Artificial Intelligence in Music*. [S.l.: s.n.], 2024.

RASCHKA, S. *Python Machine Learning*. Birmingham: Packt Publishing, 2015. ISBN 978-1783555130.

SANH, V.; DEBUT, L.; CHAUMOND, J.; WOLF, T. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. *arXiv preprint*, arXiv:1910.01108, 2019. Disponível em: <https://doi.org/10.48550/arXiv.1910.01108>.

SONG, K.; TAN, X.; QIN, T.; LU, J.; LIU, T.-Y. MPNet: Masked and Permuted Pre-training for Language Understanding. *arXiv preprint*, arXiv:2004.09297, 2020. Disponível em: <https://doi.org/10.48550/arXiv.2004.09297>.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT Models for Brazilian Portuguese. In: *Brazilian Conference on Intelligent Systems (BRACIS)*. [S.l.]: IEEE, 2020.

SPOTIFY. *Spotify for Developers – Genres and Moods API Documentation*. 2023. Disponível em: <https://developer.spotify.com/documentation/web-api/reference/get-categories>.

TSAPTSINOS, A. Lyrics-Based Music Genre Classification Using a Hierarchical Attention Network. In: *Proceedings of the 18th ISMIR Conference*. Suzhou, China: ISMIR, 2017.

TSOUMAKAS, G.; KATAKIS, I. Multi-label Classification: An Overview. *International Journal of Data Warehousing and Mining*, v. 3, n. 3, p. 1–13, 2007.

TAVARES, F. F. Multi-label Cross-lingual Automatic Music Genre Classification from Lyrics with Sentence-BERT. In: *Proceedings of the 26th ISMIR Conference*. Málaga, Espanha: ISMIR, 2025.

VASWANI, A. et al. Attention is All You Need. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.]: NeurIPS, 2017.

YANG, Z.; YANG, D.; DYER, C.; HE, X.; SMOLA, A.; HOVY, E. Hierarchical Attention Networks for Document Classification. In: *Proceedings of NAACL-HLT*. [S.l.]: ACL, 2016. p. 1480–1489.

SILVA, I. Classificação de Gêneros Musicais com SVM e TF-IDF: Um Estudo com Letras em Português. 2023. Trabalho de Conclusão de Curso (Graduação em Ciência da Computação) – Instituto Federal de São Paulo (IFSP), São Paulo, 2023.

7.1 Referências dos datasets utilizados

NEISSE, A. Scrapped Lyrics from 6 Genres. Kaggle, [s.d.]. Disponível em: <https://www.kaggle.com/datasets/neisse/scrapped-lyrics-from-6-genres>.

PANDYA, M. Spotify Tracks Dataset. Kaggle, 2022. Disponível em: <https://doi.org/10.34740/KAGGLE/DSV/4372070>.

BOGDANOV, D.; UNIVERSITAT Pompeu Fabra. Melon Playlist Dataset. Music Technology Group (MTG), 2019. Disponível em: <https://doi.org/10.5281/zenodo.2628366>.

CORDEIRO DE ALMEIDA, Y. *TCC MBA IA & Big Data – Lyrics and Music Genres Dataset*. Kaggle, 2025. Disponível em: <https://www.kaggle.com/datasets/yuricordeiro/tcc-mba-ia-usp>

GLOSSÁRIO

Acurácia: proporção de predições corretas sobre o total de instâncias testadas.

Baseline: modelo de referência usado para comparação em experimentos.

Embedding: representação densa de palavras ou textos em vetores numéricos de baixa dimensão.

Fine-tuning: ajuste fino de um modelo pré-treinado em um corpus específico.

F1-score (macro): média harmônica entre precisão e revocação, calculada igualmente para todas as classes.

Overfitting: fenômeno em que um modelo se ajusta demais aos dados de treino, perdendo capacidade de generalização.

Pooling: técnica para condensar informações em redes neurais, reduzindo a dimensionalidade (ex.: média ou máximo de ativações).

Softmax: função de ativação que transforma valores em probabilidades normalizadas para múltiplas classes.

Transformer: arquitetura de rede neural baseada em mecanismos de atenção, usada em modelos como BERT e GPT.